

ガウス過程回帰のハイパーパラメータ最適化

1. 問題設定

ガウス過程回帰(GPR: Gaussian Process Regression)では、関数 f に事前分布としてガウス過程を仮定し、観測データ $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ から予測分布を求める。本稿では最も標準的な RBF(Radial Basis Function)カーネルを用いる。

$$k(x, x') = \sigma_f^2 \exp\left(-\frac{(x - x')^2}{2\ell^2}\right)$$

観測ノイズは $y = f(x) + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$ とする。このモデルのハイパーパラメータは次の3つである。

記号	名称	役割
ℓ	長さスケール (lengthscale)	関数がどの程度の入力スケールで変動するか。小さいほど細かく波打つ関数を表現する
σ_f^2	信号分散 (signal variance)	関数の振幅(出力の縦方向の変動幅)
σ_n^2	ノイズ分散 (noise variance)	観測に乗るノイズの大きさ。データへの「あてはめの厳しさ」を制御する

2. 最適化の指標:対数周辺尤度

GPR のハイパーパラメータ最適化では、対数周辺尤度(LML: Log Marginal Likelihood)を最大化するのが標準的な方法である(第II種最尤推定、経験ベイズとも呼ばれる)。

$$\log p(\mathbf{y} | X, \theta) = -\frac{1}{2}\mathbf{y}^\top K_y^{-1}\mathbf{y} - \frac{1}{2}\log |K_y| - \frac{N}{2}\log 2\pi, \quad K_y = K + \sigma_n^2 I$$

各項の意味は次のとおり。

- 第1項(データ適合項): データをうまく説明するほど大きくなる
- 第2項(複雑さペナルティ項): モデルが柔軟すぎる(行列式が大きい)と罰則がかかる
- 第3項: 定数

この「適合とペナルティのトレードオフ」が LML に内蔵されているため、交差検証を使わなくても過適合・過平滑のバランスが自動的に取られる。これがベイズ的な「オッカムの剃刀」と呼ばれる性質である。

実装上は $\theta = (\ell, \sigma_f^2, \sigma_n^2)$ を対数空間に変換し(正值制約の処理)、L-BFGS-B などの勾配法で $-LML$ を最小化する。LML は一般に多峰性をもつため、複数の初期値から最適化を行うのが実務上の定石である。

3. 実験設定

- 真の関数: $f(x) = \sin(3x) + 0.5x$
- 観測点: $N = 15$ 点を $[-3, 3]$ から一様サンプリング
- 観測ノイズ: 標準偏差 $\sigma_n = 0.2$ のガウスノイズ
- 最適化結果(本実験): $\ell = 0.562$, $\sigma_f^2 = 2.142$, $\sigma_n^2 = 0.0044$ 、最大 LML = -8.30

なお、推定されたノイズ標準偏差($\sqrt{0.0044} \approx 0.066$)は真値 0.2 より小さい。これは事実として、 $N = 15$ という少数データでは LML 最大化による推定値にばらつきが生じうることを示している(推測として、観測点の配置上、ノイズの一部を関数の変動として説明した方が尤度が高くなったためと考えられる)。

4. 各ハイパーパラメータと尤度の関係(図1)




図1

他の2つを最適値に固定し、1つだけを動かしたときの LML の断面である。

- 長さスケール ℓ : 最適値付近に明確なピークがある。 ℓ を大きくしすぎると、ノイズ分散が小さいままではデータを説明できなくなり、LML が急落する(右側の崖)。
- 信号分散 σ_f^2 : 小さすぎるとデータの振幅を表現できず LML が大きく低下する。最適値より大きい側はピークがなだらかで、過大に設定しても尤度の低下は比較的緩やかである。
- ノイズ分散 σ_n^2 : 小さすぎる側で LML が急落する(数値的にも悪条件になりやすい)。大きすぎる側はデータの変動を「すべてノイズ」とみなす平坦なモデルに近づき、緩やかに低下する。

5. 2つのハイパーパラメータの同時依存性(図2)




図2

l と σ_n^2 の2次元等高線である。LML 最大点(星印)以外に、右上方向(長さスケール大・ノイズ大)にも尤度が比較的高い領域が広がっていることが分かる。これは「データの変動の大部分をノイズとして説明する」局所解に対応し、GPR の LML が多峰性をもつ典型例である(Rasmussen & Williams の教科書 "Gaussian Processes for Machine Learning" でも同種の図で論じられている)。初期値によってはこの局所解に収束するため、複数初期値からの最適化が推奨される。

6. ハイパーパラメータと GPR の入出力関係(図3)




図3

赤点が観測点、青実線が予測平均、青帯が予測 $\pm 2\sigma$ (約95%信頼区間)、灰色点線が真の関数である。

- 左(過適合ぎみ): ℓ とノイズ分散が小さすぎる場合。予測平均が観測点を完全に通過する一方、観測点から少し離れたとすぐ事前平均 0 に戻り、信頼区間も極端に広がる。汎化性能は低い(LML = -20.8)。
- 中央(LML 最大): 観測点の傾向を滑らかに捉え、観測点が密な領域では信頼区間が狭く、疎な領域(外挿側)では適切に広がる(LML = -8.3)。
- 右(過平滑ぎみ): ℓ とノイズ分散が大きすぎる場合。細かい変動をすべてノイズとして無視し、大局的な傾向しか捉えない(LML = -19.1)。

このように、LML の大小が「データへの適合」と「モデルの滑らかさ」のバランスの良し悪しを定量的に反映していることが確認できる。

7. fig3 の3点と尤度地形の対応関係

図4では、図3の3つのケースが図2の対数周辺尤度の等高線上のどこに位置するかを示した。




図4

- 緑の星(★ LML 最大・最適): 等高線の黄色いピーク(尤度最大領域)のほぼ中央に位置する。LML が正しく最適点を捉えていることが確認できる。

- 赤の逆三角(∇ 過適合ぎみ): 左下隅($\ell = 0.1, \sigma_n^2 = 10^{-4}$)にある。長さスケールもノイズも両方小さい極端なコーナーで、等高線が疎な低尤度の谷に対応する。
- 橙の三角($\triangle$ 過平滑ぎみ): 右上($\ell = 3.0, \sigma_n^2 = 0.5$)にある。最適点とは別の「尾根」に乗っており、第5節で述べた局所解的な高尤度領域に対応する。

これにより、図3で観察した予測の質の違い(過適合・最適・過平滑)が、尤度地形上の位置の違いとして対応づけられる。

8. まとめ

1. GPR のハイパーパラメータは対数周辺尤度(LML)の最大化で決めるのが標準であり、適合項と複雑さペナルティのトレードオフにより過適合が自動的に抑制される。
2. LML は各ハイパーパラメータに対してピークをもつが、形状は非対称で、特に ℓ や σ_n^2 が小さすぎる方向には急落する。
3. LML は多峰性をもちうるため、複数初期値からの最適化が実務上重要である。
4. データが少ない場合、LML 最大化による推定値(特にノイズ分散)は真値からずれることがある点に注意する。

付録: 図の生成コードは `gp_hyperparam_viz.py` を参照(NumPy + SciPy によるフルスクラッチ実装。Cholesky 分解で $K_y^{-1}\mathbf{y}$ と $\log |K_y|$ を計算)。